DSAI - HW4: Classic control in reinforcement learning

F74031027 李東霖

RL 題目 : Classic control: Mountain Car

action space : 0-2

0	move backward
1	stop
2	move forward

observation space : [position, velocity]

position	[-1.2 , 0.6]
velocity	[-0.07, 0.07]

reward : -1

done condition : position >= 0.5

選用的 RL 演算法 : Q-learning

Initialize $Q(s,a)$ arbitrarily
Repeat (for each episode):
  Initialize s
  Repeat (for each step of episode):
    Choose a from s using policy derived from Q (e.g., ε-greedy)
    Take action a, observe r, s'
    $Q(s,a) \leftarrow Q(s,a) + \alpha\left[r + \gamma \max_{a'} Q(s',a') - Q(s,a)\right]$
    $s \leftarrow s'$;
  until s is terminal

Figure 6.12: Q-learning: An off-policy TD control algorithm.

設計 Q-learning 狀態轉換

將 position 切成 n 個區間，並考慮速度正負再分成兩個不同狀態
總共產生 n*2 個狀態，因此狀態表為 n*2*3
下面先設定 n = 20

不同獎賞演算法的學習曲線

因為這一題剛開始看到發現 reward 都是 -1 ，第一個疑問是這樣能夠使用 RL 找到解法嗎，都是 -1 不就不知道要怎麼做才是有利的。
因此我利用設計了幾個算 reward 的方法
並把都是 -1 的 reward 稱為 origin reward

- 把 position 當作 reward 稱為 custom reward
  將 position 映射到 [-1, 1] 成為 custom reward
- 當下如果是抵達終點，給予更多 reward
  當到達終點，該 action 的 reward 為 5
  可以用在 origin reward 或 custom reward

採用總共四種 reward 算法去看看 Q-learning 跑出來的效果

- origin reward
  都是 -1
- custom reward
  介於 [-1,1]
- origin reward with done reward
  到達終點前的 reward 與 origin reward 相同
  到達終點的 reward 是 5
- custom reward with done reward
  到達終點前的 reward 與 custom reward 相同
  到達終點的 reward 是 5

alpha 設定 0.5，gamma 設定 0.7，epsilon 設定 0.01

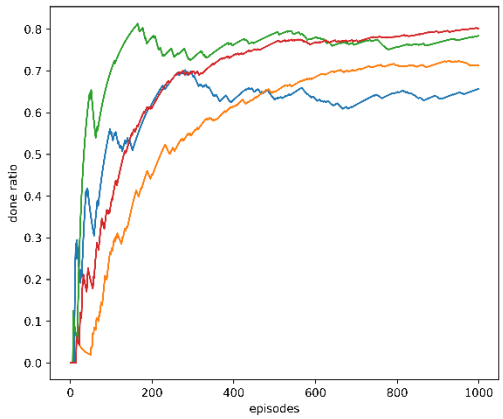

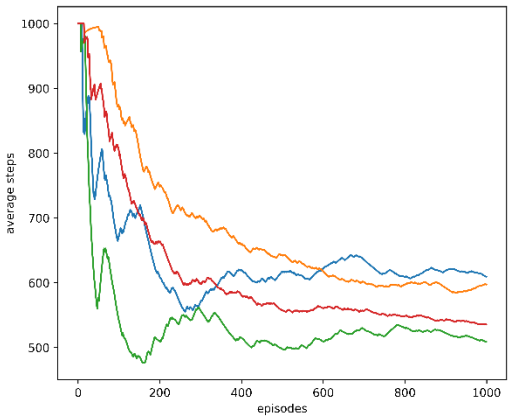

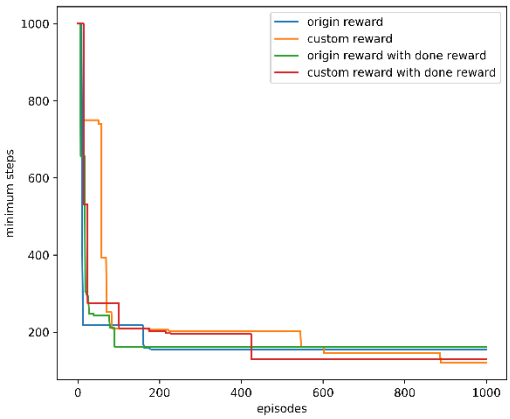

左圖是山車跑到終點的比率(完成次數 / 完成 episodes 數)
中間是到目前 episodes 的總平均 step ，越少代表使用越少 step 到達終點
右圖是到目前 episodes 的最小 step，可以看出進步幅度與速度

藉由左圖發現 custom reward 跟 custom reward with done reward 成長很穩定，不會突然掉下來
origin reward 跟 origin reward with done reward 雖然很快就有高完成率，但後來完成率卻沒有繼續成長，而且還下降，代表後來有很多 episodes 沒辦法跑到終點

然後可以發現到在跑到終點加上數量級大的 reward 是非常有幫助的
不管是用在 origin reward 或 custom reward

中間圖發現到 origin reward with done reward 有最低的平均
這個還蠻令人意外的，我想是因為都是 -1 reward 突然出現一個大的 reward 對整個 model 有非常大的幫助，因此能快速有低的 steps ，就算後面表現不佳也可以保持低平均

右圖則呈現出 custom reward 能夠確實讓 model 持續有學習到該怎麼走
不像 origin reward 到後來都沒辦法讓 step 變得更低

不同參數的學習曲線

基本預設參數

$\alpha = 0.5,\ \gamma = 0.7,\ \varepsilon = 0.01, \text{state}_{\text{number}} = 20,$

$\text{episode}_{\text{size}} = 1000, \text{maxStep}_{\text{episode}} = 1000$

使用的獎賞算法是 custom reward with done reward

學習率 α

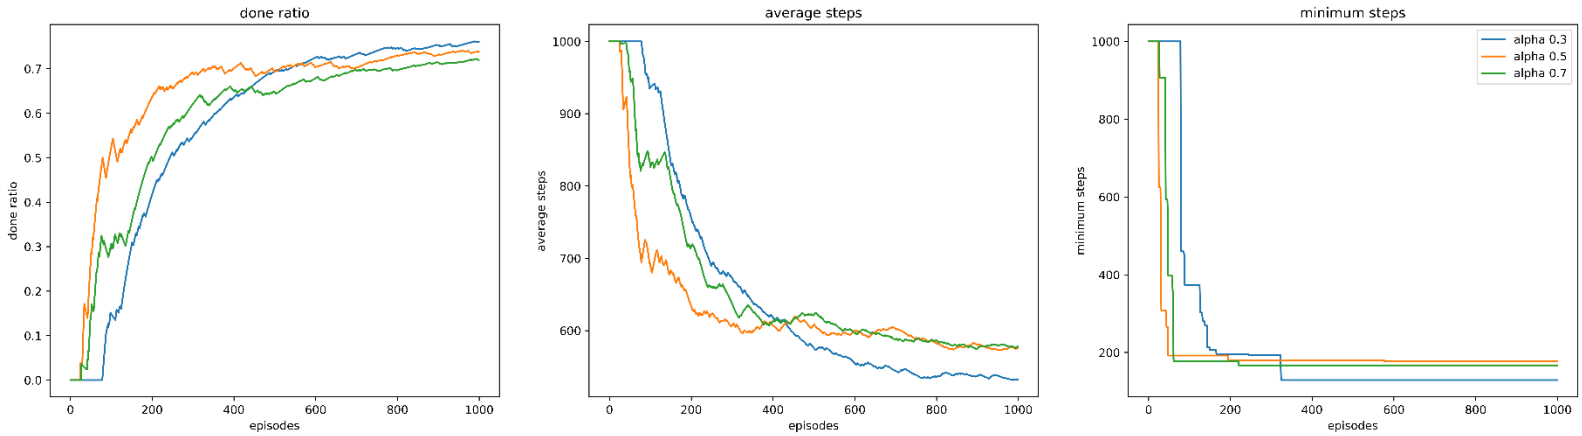

看起來當 0.3 時表現較佳，應該是因為學習到更多環境回饋跟過往記憶的 reward

衰退因子 γ

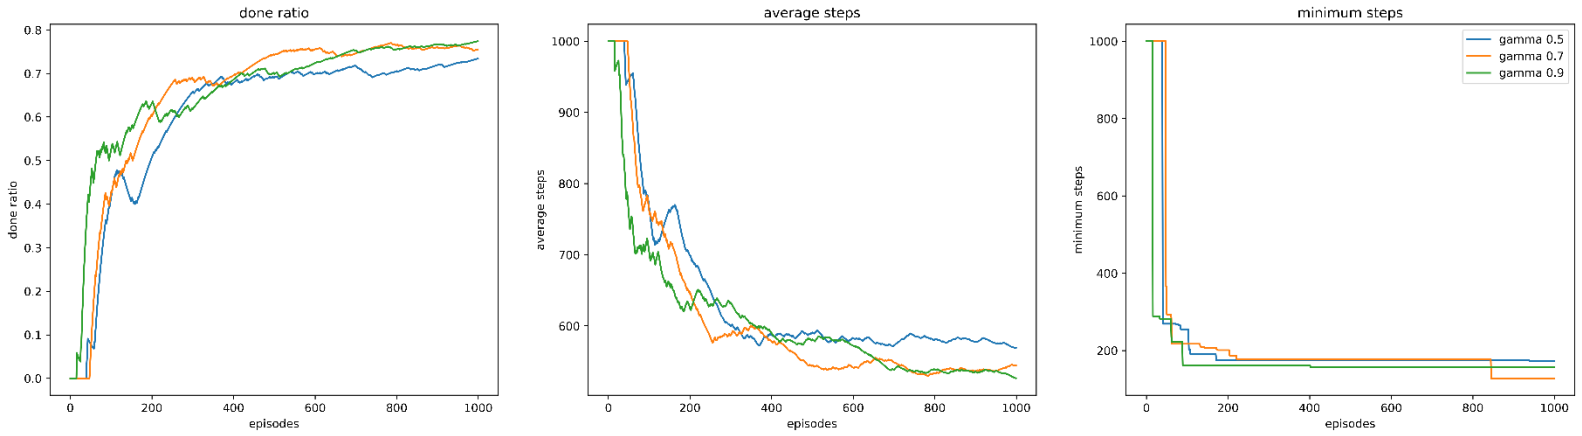

雖然 0.7 時，稱不上最好，可是在右圖可以看到他能更進一步的變好

隨機選擇率 ε

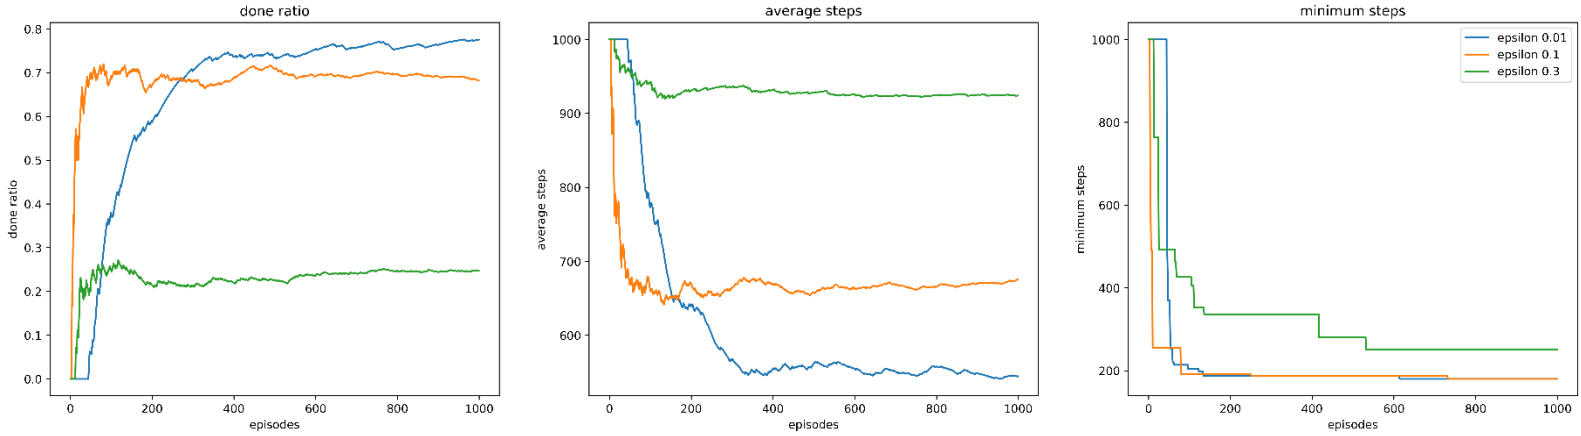

這裡就很有趣了，差異非常大，當 0.01 時大獲全勝
雖然在左圖看到進步神速，但是卻後繼無力，無法繼續進步

問題回答

1. Q: What kind of RL algorithms did you use? value-based, policy-based, model-based? why?

   A: 我使用 Q-learning。是 value-based 的, 因為 Q-learning 是更新在不同 state 中不同 action 所得到 return value。並且在選擇 action 時，選擇該 state 中擁有最高 return value 的 action。

2. Q: This algorithms is off-policy or on-policy? why?

   A: 是 off-policy 的，因為在更新 value 的公式當中，是對即將到達的 state 進行 argmax 藉此取得之前訓練中最大 value 的 action。但不一定在下一個 step 會選擇相同的 action。

3. Q: How does your algorithm solve the correlation problem in the same MDP?

   A: 在更新 value 公式當中

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma * max_{a'} Q(s',a') - Q(s,a)]$$

   發現到 Q-learning 只在意當下 state 與選擇 action 到達後的 state

   並沒有去處理在 MDP 的 correlation problem